

LAPORAN PROYEK MACHINE LEARNING

**Sistem Deteksi Dini Stunting melalui Klasifikasi Data Antropometri
Terintegrasi (Web dan Mobile)**



Disusun Oleh:

- 11423004 : Marselino Tambunan**
- 11423033 : Rino Jeremia Christopher Gultom**
- 11423035 : Elisabeth Pasaribu**
- 11423060 : Gracia Anggraini Manik**
- 11423066 : Stefani Margareth Rajagukguk**

**PROGRAM STUDI D4 TEKNOLOGI REKAYASA
PERANGKAT LUNAK**

INSTITUT TEKNOLOGI DEL 2026

Daftar Halaman

BAB I PENDAHULUAN	3
1.1 Latar Belakang	3
1.2 Rumusan Masalah	3
1.3 Tujuan Proyek	3
1.4 Manfaat Proyek	4
1.4.1 Manfaat Akademik	4
1.4.2 Manfaat Praktis	4
BAB II TINJAUAN PUSTAKA.....	5
2.1 Karakteristik Machine Learning.....	5
2.2 Teknologi Yang Digunakan	5
BAB III ANALISIS DAN PERANCANGAN SISTEM	7
3.1 Analisis Sistem.....	7
3.2 Perancangan Sistem	7
BAB IV HASIL DAN ANALISIS.....	11
4.1 Hasil	11
4.1.1 Hasil Pengujian	11
4.1.2 Hasil Evaluasi.....	11
4.1.3 Hasil Visualisasi	11
4.2 Analisis Sistem.....	14
BAB V KESIMPULAN	15
5.1 Kesimpulan.....	15

BAB I PENDAHULUAN

1.1 Latar Belakang

Stunting merupakan salah satu penyakit di mana tinggi badan anak lebih rendah dari rata-rata untuk usianya karena kekurangan nutrisi. Proses pemantauan anak masih dilakukan dengan cara manual sehingga sering kali menyebabkan keterlambatan dalam mendeteksi risiko stunting. Oleh karena itu, diperlukan sistem yang dapat membantu orang tua dan bidan dalam memantau kondisi pertumbuhan anak dengan cara yang lebih cepat, mudah dan terintegrasi dengan data tinggi badan, berat badan, usia.

Dalam hal masalah tersebut, maka dikembangkan Sistem Deteksi Dini Stunting melalui Klasifikasi Data Antropometri Terintegrasi (Web dan Mobile). Sistem yang dikembangkan mampu mendeteksi risiko stunting berdasarkan pola data pertumbuhan anak dan menampilkan hasil tingkat risiko stunting melalui integrasi API, sehingga dengan adanya sistem ini, proses monitoring dan pengambilan keputusan awal terkait risiko stunting dapat lebih efektif dan efisien.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah proyek ini adalah:

1. Bagaimana membangun model machine learning yang dapat mendeteksi risiko stunting pada anak berdasarkan data pertumbuhan dan kesehatan anak?
2. Bagaimana melakukan preprocessing dan feature engineering untuk data pertumbuhan anak sehingga dapat digunakan secara optimal untuk pelatihan model machine learning?
3. Bagaimana cara meningkatkan performa kualitas model untuk mendeteksi stunting pada dataset yang memiliki missing value dan imbalanced data?
4. Bagaimana mengintegrasikan model machine learning yang telah dibuat ke dalam layanan API dengan FastAPI agar hasil deteksi dapat diakses dengan web dan mobile?

1.3 Tujuan Proyek

Tujuan dari proyek ini adalah:

1. Membangun model machine learning yang dapat mendeteksi risiko stunting pada anak berdasarkan data pertumbuhan dan kesehatan anak.
2. Melakukan preprocessing dan feature engineering untuk menghasilkan data dan fitur yang sesuai sehingga meningkatkan kualitas untuk melatih model.
3. Meningkatkan performa model untuk mendeteksi stunting pada dataset yang memiliki missing value dan imbalanced data melalui preprocessing, oversampling dan hyperparameter tuning.
4. Mengintegrasikan model machine learning pada layanan API menggunakan FastAPI sehingga dapat diakses dan digunakan pada web dan mobile.

1.4 Manfaat Proyek

1.4.1 Manfaat Akademik

Manfaat proyek ini memberikan kontribusi akademik yaitu implementasi nyata penerapan machine learning pada kesehatan ibu dan anak, khususnya pada deteksi risiko stunting pada anak. Proyek ini menghasilkan tahapan machine learning pipeline yaitu mulai dari tahap data source, data ingestion, data preprocessing, target engineering, feature engineering, train/test split dan oversampling, pelatihan model sebelum tuning, hyperparameter tuning dan evaluasi model. Selain itu proyek juga menunjukkan integrasi model machine learning pada layanan API berbasis FastAPI yang dapat diakses dengan aplikasi web dan mobile.

1.4.2 Manfaat Praktis

Manfaat proyek dari sisi praktis adalah sistem ini dapat digunakan untuk membantu proses deteksi dini risiko stunting pada anak berdasarkan data pertumbuhan dan kesehatan anak. Integrasi layanan API berbasis FastAP memungkinkan hasil deteksi dapat digunakan dengan fleksibel pada web ataupun mobile, sehingga memudahkan bidan dan orang tua dalam melakukan monitoring pertumbuhan anak dengan lebih efisien. Pada halaman data anak interaktif dibangun untuk memungkinkan bidan melihat hasil deteksi dan informasi pertumbuhan anak.

BAB II TINJAUAN PUSTAKA

2.1 Karakteristik Machine Learning

Proyek ini menggunakan machine learning terawasi, karena model dilatih menggunakan data yang telah memiliki label kelas yaitu normal dan stunting. Masalah yang diselesaikan adalah klasifikasi biner, yaitu menentukan apakah seorang anak termasuk kategori stunting atau tidak. Data yang digunakan memiliki karakteristik nyata, seperti adanya missing value, noise, dan ketidakseimbangan kelas, sehingga perlu dilakukan preprocessing, feature engineering, dan oversampling sebelum pelatihan model. Pada tahap pemodelan, dilakukan perbandingan performa sebelum dan sesudah tuning hyperparameter agar model yang dihasilkan lebih optimal. Hasil deteksi kemudian disajikan melalui layanan API, sehingga model tidak hanya berhenti di tahap training, tetapi juga bisa digunakan langsung oleh aplikasi lain.

2.2 Teknologi Yang Digunakan

Berikut adalah teknologi utama yang digunakan dalam proyek ini:

Tabel 1. Teknologi yang Digunakan

No	Teknologi	Kategori	Fungsi dalam Proyek
1.	Python	Bahasa Pemrograman	Bahasa yang digunakan untuk pipeline machine learning, pengolahan data dan backend API.
2.	Pandas	Data Processing Library	Digunakan untuk membaca, membersihkan, mentransformasi, dan mengelola data ketika preprocessing.
3.	NumPy	Numerical Computing Library	Digunakan untuk operasi numerik, manipulasi array, dan perhitungan matematis.
4.	Scikit-learn	Machine Learning Library	Digunakan untuk pembagian data, normalisasi data, evaluasi model dan hyperparameter tuning dengan GridSearchCV
5.	XGBoost	Machine Learning Algorithm	Digunakan untuk klasifikasi hal mendeteksi risiko stunting dengan pendekatan gradient boosting .

No	Teknologi	Kategori	Fungsi dalam Proyek
6.	Random Forest	Machine Learning Algorithm	Digunakan untuk klasifikasi berbasis ensemble untuk mendeteksi risiko stunting dan membandingkan performa model.
7.	Imbalanced-learn	Data Balancing Library	Digunakan untuk menangani ketidakseimbangan kelas menggunakan teknik oversampling seperti SMOTE.
8.	FastAPI	Backend Framework / API Framework	Digunakan untuk membangun REST API sehingga model deteksi dapat diakses oleh aplikasi lain secara cepat dan efisien.
9.	Streamlit	Dashboard & Web Application Framework	Digunakan untuk membuat dashboard interaktif, menampilkan hasil evaluasi model, visualisasi data, dan form deteksi.
10.	Matplotlib	Data Visualization Library	Digunakan untuk membuat visualisasi data dan hasil analisis seperti confusion matrix, distribusi data, dan feature importance.

BAB III ANALISIS DAN PERANCANGAN SISTEM

3.1 Analisis Sistem

Sistem Deteksi Dini Stunting melalui Klasifikasi Data Antropometri Terintegrasi (Web dan Mobile) dirancang untuk membantu proses identifikasi awal untuk risiko stunting pada anak berdasarkan data kesehatan dan pertumbuhan anak. Dengan sistem ini, maka bidan akan mendapatkan informasi tentang hasil deteksi dengan lebih cepat tanpa harus melakukan analisis manual secara penuh.

Hasil data training menunjukkan bahwa dua model yang dibandingkan yaitu Random Forest dan XGBoost memiliki kesamaan pada accuracy yang tinggi sekitar 0.98. Tetapi nilai pada F1-score masih dalam kategori rendah karena jumlah data kelas stunting lebih sedikit dibanding kelas normal. Hasil dari XGBoost digunakan sebagai model terbaik karena memiliki F1-score sedikit lebih baik dibanding dengan model Random Forest yaitu 0.4444 dibanding dengan 0.4000, nilai ini menunjukkan jika hanya accuracy saja maka tidak akan cukup untuk menilai performansi mode terutama untuk imbalanced data.

3.2 Perancangan Sistem

Perancangan sistem dilakukan untuk memastikan seluruh proses, mulai dari pembacaan data sampai penyajian hasil deteksi, berjalan secara terstruktur. Sistem ini terdiri dari beberapa komponen utama, yaitu data source, data ingestion, preprocessing, feature engineering, training model, evaluasi model, penyimpanan model, dan penyajian hasil melalui FastAPI serta Streamlit.

Berikut adalah tahapan perancangan sistem.

1. Fase Persiapan dan Eksplorasi Data Awal

- Load dataset

Sumber data yang digunakan untuk melatih model klasifikasi risiko stunting dari file `raw_dataset.csv` yang berisi 9.931 baris dan 35 kolom. Dataset ini berisi data kesehatan anak yang digunakan sebagai data utama dalam proses pengembangan model.

```
DATA_PATH = 'raw_dataset.csv'

df_raw = pd.read_csv(DATA_PATH, sep=',')
print(f"Dataset berhasil dimuat")
print(f"Jumlah baris : {df_raw.shape[0]},")
print(f"Jumlah kolom : {df_raw.shape[1]}")
print(f"Daftar kolom:")
for i, col in enumerate(df_raw.columns, 1):
    print(f"({i:2d}). {col}")

Dataset berhasil dimuat
Jumlah baris : 9,931
Jumlah kolom : 35

Daftar kolom:
1. NIK
2. Nama
3. JK
4. Tgl Lahir
5. BB Lahir
6. TB Lahir
7. Nama Ortu
8. Prov
9. Kab/Kota
10. Kec
11. Puskesmas
12. Desa/Kel
13. Posyandu
14. RT
15. RW
16. Alamat
17. Usia Saat Ukur
18. Tanggal Pengukuran
19. Berat
20. Tinggi
...
32. KIA
33. Kelas Ibu Balita
34. PEG
```

2. Fase Pembersihan dan Rekayasa Data

Pada tahap ini, data dibersihkan untuk pengembangan model meliputi:

- Koreksi satuan berat badan lahir (konversi nilai dalam gram menjadi kilogram).
- Penghapusan outlier fisik tak wajar berdasarkan batas biologis balita usia 0–5 tahun.
- Pemotongan (clipping) nilai ekstrem pada ZS BB/U ke rentang $[-5, 5]$.
- Imputasi nilai kosong pada fitur Lingkar Lengan Atas (LiLA) menggunakan nilai median.

Target diklasifikasikan menjadi 4 kelas sesuai standar WHO (ZS TB/U):

- Normal (≥ -1 SD)
- Risiko Stunting Ringan (-2 SD $\leq$ ZS < -1 SD)
- Risiko Stunting Sedang (-3 SD $\leq$ ZS < -2 SD)
- Risiko Stunting Tinggi (< -3 SD)

Feature engineering:

- kalkulasi Body Mass Index (BMI)
- Growth Velocity (kecepatan tumbuh berat dan tinggi per bulan)
- encoding untuk Jenis Kelamin (JK)
- status Naik Berat Badan
- Cara Ukur.

Feature Filtering:

Penghapusan lebih dari 20 kolom yang tidak relevan (data administratif dan identitas) serta kolom yang menyebabkan kebocoran data (data leakage), seperti ZS TB/U dan label status gizi lainnya.

3. Fase Analisis Visual dan Persiapan Fitur

Exploratory Data Analysis (EDA) meliputi:

- kurva kepadatan (KDE) per kelas target
- boxplot antropometri utama
- heatmap korelasi antar-fitur vs target
- scatter plot untuk melihat sebaran tinggi dan berat badan terhadap usia balita.

Train-Test Split: Pembagian dataset menggunakan rasio 80% data latih (training) dan 20% data uji (testing) dengan metode stratified agar proporsi kelas target tetap terjaga konsisten di kedua himpunan data.

Preprocessing: Penerapan LabelEncoder untuk mengubah target menjadi nilai numerik dan StandardScaler untuk normalisasi skala fitur (di-fit secara eksklusif pada data latih guna menghindari data leakage).

Feature Selection: Pemilihan fitur secara obyektif menggunakan Mutual Information (MI) dan Random Forest Feature Importance. Hanya fitur dengan nilai $MI \geq 0.005$ yang lolos seleksi (dengan jaminan batas minimal 5 fitur utama).

- s

4. Data Preprocessing

Tahap preprocessing dilakukan untuk membersihkan data agar meningkatkan kualitas dataset

sebelum digunakan pada proses analisis dan pemodelan machine learning. Pada tahap ini melakukan menghapus missing value sebanyak 120 baris data, melakukan pemeriksaan data setelah pembersihan dan transformasi dengan jumlah data tersisa yaitu 6.649 data, selanjutnya adalah melakukan proses penyaringan atau filtering dengan jumlah data 4.969 data.

```
[2/8] Preprocessing data...  
Missing values dibuang: 120 baris  
rfa Missing setelah preprocessing: 6649  
rfa Total data setelah filtering: 4,969
```

5. Target Engineering

Target engineering dilakukan untuk membentuk label kelas yang akan dideteksi. Pada proyek ini, label stunting dibentuk dari nilai ZS TB/U lalu data dikategorikan ke dalam kelas normal atau stunting. Pada distribusi kelas stunting label normal sebesar 98.7% atau sebanyak 4.902 data dan untuk label stunting sebesar 1.3% atau sebanyak 67 data. Sehingga masalah yang diselesaikan menjadi klasifikasi biner.

```
[3/8] Membentuk target label stunting...  
  
Distribusi kelas stunting:  
| NORMAL           : 4,902 (98.7%)  
| STUNTING         : 67 (1.3%)
```

6. Feature Engineering

Feature engineering dilakukan untuk membuat informasi tambahan dari data yang sudah ada sehingga machine learning dapat menganali pola dengan lebih bagus. Fitur baru yang ditambah adalah BMI (Indeks Massa Tubuh), rasio berat badan terhadap tinggi badan (BB/TB ratio), pertambahan tinggi badan (growth height), dan pertambahan berat badan (growth weight). Fitur yang ditambahkan membantu model untuk memperoleh informasi yang lebih lengkap tentang kondisi pertumbuhan anak sehingga hasil deteksi stunting menjadi lebih akurat.

```
[4/8] Feature engineering...  
| rfa Total fitur: 15
```

7. Train/Test Split & Oversampling

Pada tahap ini data dibagi menjadi dua yaitu data yang akan digunakan untuk dilatih dan data yang digunakan untuk diuji sehingga evaluasi model dapat dilakukan secara objektif. Data yang digunakan untuk dilatih diseimbangkan dengan oversampling karena jumlah kelas yang tidak seimbang. Pada tahap ini model tidak hanya belajar dari kelas mayoritas tetapi mampu mengenali kelas minoritas.

```
[5/8] Split data dan penanganan class imbalance...  
Train: 3,975 | Test: 994  
Setelah oversampling: {0: 3921, 1: 3921}
```

8. Pelatihan Model (Sebelum Tuning)

Pada tahap ini, model dilatih menggunakan dua algoritma, yaitu Random Forest dan XGBoost. Pelatihan awal dilakukan untuk memperoleh baseline performa masing-masing model. Berdasarkan hasil yang tercatat pada output training, sebelum tuning kedua model memperoleh accuracy yang sangat tinggi, namun F1-score pada kelas minoritas masih rendah. Hal ini menunjukkan bahwa model masih lebih baik dalam mengenali kelas normal dibanding kelas stunting.

```
[6/8] Melatih model (sebelum tuning)...  
RF sebelum tuning : Akurasi = 0.9879  
XGB sebelum tuning: Akurasi = 0.9759
```

9. Hyperparameter Tuning — GridSearchCV

Tahap hyperparameter tuning dilakukan dengan GridSearchCV yaitu untuk mencari kombinasi parameter terbaik untuk meningkatkan performa model. Hasil dari hyperparameter tuning pada random forest adalah memperoleh parameter terbaik dengan `n_estimators=100`, `max_depth=None`, `min_samples_leaf=1`, dan `min_samples_split=2`. Pada XGBoost memperoleh parameter terbaik dengan `colsample_bytree=1.0`, `learning_rate=0.1`, `max_depth=4`, `n_estimators=200`, dan `subsample=1.0`.

```
[7/8] Hyperparameter Tuning (GridSearchCV 5-fold CV)...  
>> Tuning Random Forest...  
RF best params : {'max_depth': None, 'min_samples_leaf': 1, 'min_samples_split': 2, 'n_estimators': 100}  
RF best CV F1 : 0.9971  
>> Tuning XGBoost...  
XGB best params: {'colsample_bytree': 1.0, 'learning_rate': 0.1, 'max_depth': 4, 'n_estimators': 200, 'subsample': 1.0}  
XGB best CV F1 : 0.9950
```

10. Evaluasi Model (Setelah Tuning)

Evaluasi dilakukan menggunakan metrik accuracy, precision, recall, F1-score, dan ROC AUC. Berdasarkan hasil yang tersimpan di `training_report.json`. Pada random forest menghasilkan Accuracy: 0.9879, F1-score: 0.4000. Pada XGBoost menghasilkan Accuracy: 0.9849 dan F1-score: 0.4444. XG Boost dipilih sebagai model terbaik karena hasil F1-Score lebih baik. Hasil F1-Score cocok digunakan untuk data yang tidak seimbang, terutama ketika kelas minoritas seperti stunting lebih penting untuk dikenali dengan benar.

[8/8] Evaluasi model final...

```
=====
#f0|| RANDOM FOREST PERFORMANCE (Setelah Tuning)
=====
Akurasi : 0.9879 (98.79%)
ROC AUC : 0.9230
F1 Score : 0.4000
precision recall f1-score support
NORMAL 0.99 1.00 0.99 981
STUNTING 0.57 0.31 0.40 13
accuracy 0.99 994
macro avg 0.78 0.65 0.70 994
weighted avg 0.99 0.99 0.99 994
Cross-Val (5-fold): 0.9899 T 0.0017
```

```
=====
#f0|| XGBOOST PERFORMANCE (Setelah Tuning)
=====
Akurasi : 0.9849 (98.49%)
ROC AUC : 0.9423
F1 Score : 0.4444
precision recall f1-score support
NORMAL 0.99 0.99 0.99 981
STUNTING 0.43 0.46 0.44 13
accuracy 0.98 994
macro avg 0.71 0.73 0.72 994
weighted avg 0.99 0.98 0.99 994
```

BAB IV HASIL DAN ANALISIS

4.1 Hasil

4.1.1 Hasil Pengujian

Hasil pengujian menunjukkan jika kedua model yang digunakan memiliki performa yang baik dalam melakukan pendeteksian. Pada random forest memperoleh akurasi sebesar 98,79% dengan nilai F1-Score 0,4000. Sedangkan pada XGBoost memperoleh akurasi sebesar 98,49% dengan nilai F1-Score 0,4444. Pada hasil akhir, akurasi random forest merupakan hasil yang lebih tinggi, namun XGBoost memiliki nilai F1-Score yang lebih baik, yang menunjukkan kemampuan yang lebih baik dalam menyeimbangkan prediksi antara kelas positif dan negatif pada kasus prediksi risiko stunting.

Random Forest	Akurasi: 0.9879 (98.79%)	F1: 0.4000
XGBoost	Akurasi: 0.9849 (98.49%)	F1: 0.4444

4.1.2 Hasil Evaluasi

Hasil evaluasi dari kedua model berhasil melampaui target akurasi yang ditetapkan, yaitu di atas 80%. Random Forest memperoleh akurasi sebesar 98,79% dan XGBoost memperoleh akurasi sebesar 98,49%. Hasil tersebut menunjukkan bahwa kedua model memiliki kemampuan prediksi yang sangat baik. Pada nilai F1-Score yang masih berada di bawah 0,5 menunjukkan bahwa performa model dalam mengidentifikasi kelas minoritas masih perlu diperhatikan, sehingga evaluasi tidak hanya berfokus pada akurasi tetapi juga mempertimbangkan metrik lain seperti precision, recall, dan F1-Score.

TARGET AKURASI > 0.80

4.1.3 Hasil Visualisasi

Pada visualisasi akan berisi form data kesehatan anak yang diperlukan untuk memprediksi apakah anak stunting, memiliki risiko stunting atau normal. Berikut adalah visualisasi hasil prediksi apakah anak stunting, memiliki risiko stunting atau normal.

1. Prediksi Normal

Stunting ML Dashboard

Ringkasan hasil training, perbandingan tuning, dan prediksi interaktif dalam satu tampilan.

Baris data	Fitur relevan	Label stunting	Label normal
9,931	11	68	9,863

Prediksi Interaktif

Berat badan lahir (kg)

3.10 - +

Tinggi badan lahir (cm)

49.00 - +

Berat badan saat ukur (kg)

10.50 - +

Tinggi badan saat ukur (cm)

92.00 - +

LiLA (cm)

13.50 - +

Umur (bulan)

27

Jenis kelamin

☐ Laki-laki ☒ Perempuan

Jalankan Prediksi

Risiko stunting

24.00%

Klasifikasi

NORMAL

Confidence

76.00%

Status TB/U: Normal

Pertumbuhan anak normal. Lanjutkan pola makan sehat dan pemantauan rutin.

Hasil Training

Before tuning

	Random Forest	XGBoost
Accuracy	-	-
ROC AUC	-	-
Precision	-	-
Recall	-	-
F1	-	-

After tuning (GridSearchCV)

	Random Forest	XGBoost
Accuracy	-	-
ROC AUC	-	-
Precision	-	-
Recall	-	-

2. Prediksi At Risk

Stunting ML Dashboard

Ringkasan hasil training, perbandingan tuning, dan prediksi interaktif dalam satu tampilan.

Baris data	Fitur relevan	Label stunting	Label normal
9,931	11	68	9,863

Prediksi Interaktif

Berat badan lahir (kg)

3.10 - +

Tinggi badan lahir (cm)

49.00 - +

Berat badan saat ukur (kg)

10.50 - +

Tinggi badan saat ukur (cm)

62.50 - +

LiLA (cm)

13.50 - +

Umur (bulan)

43

Jenis kelamin

☐ Laki-laki ☒ Perempuan

Jalankan Prediksi

Risiko stunting

65.00%

Klasifikasi

AT_RISK

Confidence

65.00%

Status TB/U: Pendek

RISIKO SEDANG. Perlu pemantauan rutin dan edukasi nutrisi.

Hasil Training


Before tuning

	Random Forest	XGBoost
Accuracy	-	-
ROC AUC	-	-
Precision	-	-
Recall	-	-
F1	-	-

After tuning (GridSearchCV)

	Random Forest	XGBoost
Accuracy	-	-
ROC AUC	-	-
Precision	-	-
Recall	-	-

3. Prediksi Stunting



4.2 Analisis Sistem

Hasil perbandingan performa menunjukkan jika kedua model memiliki tingkat akurasi yang sangat tinggi yaitu diatas 98%. Pada random forest memiliki hasil akurasi sebesar 98,79% dengan F1-Score 0,40, sedangkan XGBoost hasil akurasi sebesar 98,49% dengan F1-Score 0,444. Hasil akurasi Random Forest sedikit lebih tinggi, nilai F1-Score XGBoost yang lebih baik menunjukkan bahwa model tersebut lebih mampu mengenali kelas minoritas, yaitu kasus stunting, setelah dilakukan penanganan ketidakseimbangan data dan proses hyperparameter tuning. Pada dataset yang tidak seimbang hasil akurasi yang tinggi tidak selalu mencerminkan performa model sebenarnya, sehingga metrik F1-Score lebih relevan karena mempertimbangkan keseimbangan antara precision dan recall. Model akhir yang lebih digunakan ada pada nilai F1-Score dan *recall* untuk meminimalkan kesalahan prediksi pada kasus stunting (false negative).

BAB V KESIMPULAN

5.1 Kesimpulan

Berdasarkan hasil pelatihan dan evaluasi model, XGBoost dipilih menjadi model terbaik untuk implementasi sistem prediksi risiko stunting. Pada hasil prediksi random forest memperoleh akurasi sedikit lebih tinggi (98,79%) dibandingkan XGBoost (98,49%), namun nilai F1-Score XGBoost lebih baik, yaitu 0,4444 dibandingkan 0,40. Hal ini menunjukkan bahwa XGBoost lebih mampu mendeteksi kasus stunting sebagai kelas minoritas, sehingga lebih sesuai digunakan pada permasalahan klasifikasi kesehatan yang memerlukan deteksi kasus positif secara akurat.

Perbedaan antara akurasi dan F1-Score menunjukkan bahwa ketidakseimbangan data masih memengaruhi performa model. Oleh karena itu, pemilihan model tidak hanya didasarkan pada akurasi, tetapi juga mempertimbangkan kemampuan model dalam mengenali kelas stunting. Seluruh artefak model, termasuk model hasil pelatihan, scaler, daftar fitur, dan laporan evaluasi telah berhasil disimpan, sehingga sistem siap diimplementasikan melalui FastAPI dan Streamlit. Meskipun demikian, pengujian lebih lanjut menggunakan dataset eksternal masih diperlukan untuk memastikan kemampuan generalisasi model terhadap data baru.